EXAMEN PAR LES PAIRS PAR SERVICES PARTAGÉS CANADA DU TRIAGE D'ANALYTIQUE AVANCÉE POUR LES DEMANDES DE FICHES DE VISITEURS

SOMMAIRE

Immigration, Réfugiés et Citoyenneté Canada
Immigration, Refugees and Citizenship Canada
Canada

Sommaire

Le rapport d'évaluation par les pairs évalue une application d'intelligence artificielle développée par Immigration, Réfugiés et Citoyenneté Canada (IRCC) pour le programme des *fiches de visiteurs* (FV). Une évaluation est une exigence obligatoire de la Directive sur la prise de décisions automatisée du Secrétariat du Conseil du Trésor du Canada (SCT) et évalue les modèles d'apprentissage automatique d'IRCC qui aident à évaluer la recevabilité de toutes les demandes de fiches de visiteurs. L'application d'IRCC à l'étude signale les demandes courantes pour une approbation automatisée de la recevabilité en s'appuyant sur une série de règles élaborées par le personnel d'IRCC en tandem avec un modèle d'apprentissage automatique sur mesure. L'évaluation révèle que la solution d'IRCC est robuste et que les contrôles et mesures de protection nécessaires ont été suffisamment décrits pour garantir la protection de la vie privée des demandeurs tout au long de son cycle de vie.

Approche

Pendant le processus d'évaluation par les pairs, une équipe de scientifiques des données et d'analystes opérationnels de Services partagés Canada (SPC) a travaillé avec IRCC pour comprendre le processus des fiches de visiteurs et les outils de soutien de l'IA. L'équipe de SPC s'est référée au document de Bronson/Millar intitulé « *Examen par les pairs des outils de prise de décisions automatisée en vertu de la Directive sur la prise de décisions automatisée du Canada; un processus modèle d'examen par les pairs et des recommandations pour les pratiques exemplaires»,* au Guide sur l'examen par les pairs du SCT (ébauche) et à la liste de contrôle connexe, à la Directive sur la prise de décisions automatisée du SCT (Directive), pour guider le processus d'évaluation.

Constatations

Tout au long du processus d'évaluation, SPC a découvert des cas où la documentation fournie ne reflétait pas entièrement le déploiement actuel du système et où les informations pertinentes issues des discussions étaient absentes. Toutes les divergences découvertes ont été signalées à IRCC pour enquête. IRCC a confirmé son intention de résoudre toutes les divergences.

L'examen démontre que le personnel d'IRCC a élaboré ses modèles conformément aux objectifs du SCT en matière de transparence et d'atténuation des risques.

Recommendations

Équité

Risque de discrimination lié au réétiquetage des dossiers : Tout ajustement (réétiquetage) apporté aux données de formation doit être soigneusement évalué pour s'assurer qu'il n'introduit pas de biais contre des groupes spécifiques de demandeurs. Si les données sur les infractions et le redressement des décisions d'approbation à refus ne sont pas représentatives de tous les groupes, il existe un risque que le modèle apprenne à discriminer en fonction de ces biais. IRCC reconnaît qu'il existe toujours un risque inhérent d'introduire un biais lors du réétiquetage des données de formation. Au fur et à mesure que les prochaines itérations du modèle seront élaborées, IRCC s'engage à continuer de surveiller le modèle pour s'assurer qu'aucun groupe spécifique de demandeurs ne subit de biais.

Risque de discrimination lié aux mesures externes et/ou aux événements indésirables : Dans les prochaines itérations de formation, il est recommandé de distinguer clairement les dossiers qui ont été approuvés ou refusés en fonction d'événements indésirables permanents ou temporaires ou externes tels qu'une situation sanitaire changeante, des facteurs politiques/gouvernementaux ou d'autres événements indésirables afin d'éviter d'introduire des classifications permanentes ou d'autres formes de discrimination. Comme la décision finale est toujours supervisée par un agent, le risque global reste faible, mais doit être clairement signalé. IRCC poursuivra sa pratique de collecte d'informations sur l'évolution des conditions dans les pays afin de s'assurer que les décisions prises par les modèles et les humains intègrent les développements récents. Le risque de biais sera atténué par l'examen de toutes les nouvelles règles et en effectuant une analyse comparative entre les sexes plus des résultats du triage.

Dépendance excessive

La confiance des agents dans le processus de triage peut biaiser les décisions : Il existe un risque que les agents deviennent trop dépendants du système de triage, ce qui pourrait avoir une incidence sur leur prise de décision en matière d'interdiction de territoire. Les agents pourraient ne pas naviguer les multiples onglets et champs pour apprécier l'évaluation complète du modèle. Il est important de souligner que les agents doivent maintenir une approche critique lors de l'examen des demandes, en s'assurant de ne pas faire aveuglément confiance aux résultats automatisés. De plus, il est nécessaire de surveiller de près les décisions liées aux événements indésirables pour s'assurer qu'elles sont examinées en profondeur. IRCC reconnaît que le biais d'automatisation est un risque inhérent à tous les modèles d'automatisation. Pour en tenir compte, le plan d'assurance qualité du modèle de FV comprend un volet d'assurance qualité « à l'aveugle » pour atténuer le risque de biais d'automatisation chez les décideurs.

Modèle

La validation du modèle par validation croisée augmenterait la performance : pour améliorer les capacités de généralisation du modèle, il est recommandé de mettre en œuvre des techniques de validation croisée pendant la formation. Cette approche permettra de vérifier la performance du modèle sur des données non vues et de garantir sa robustesse face au surajustement, améliorant ainsi sa fiabilité dans les applications du monde réel.

Le Centre de solutions en analytique avancée d'IRCC (CSAA) a décidé que pour les futurs modèles, des étapes de validation croisée seront utilisées pour la formation du modèle afin de prouver la robustesse du modèle. Cependant, les procédures actuelles de création de modèles comprennent une étape de test qui utilise 30 % de données de test non vues pour garantir l'absence de surajustement.

Confidentialité

La gestion des données liées à la protection de la vie privée et la sécurité continueront d'être des risques continus: Comme indiqué dans la documentation fournie et les annexes associées, les données utilisées pour la formation des modèles contiennent des renseignements personnels sensibles et sont gérées selon des protocoles de sécurité stricts. Bien qu'elles soient hébergées dans un environnement infonuagique protégé, l'interface avec d'autres systèmes et le transfert de données peuvent présenter des risques potentiels. Une vigilance continue et des mesures de sécurité rigoureuses sont essentielles pour atténuer les risques associés aux incohérences ou aux inexactitudes des données. IRCC maintiendra sa vigilance à l'égard de la diffusion interne de renseignements personnels.

Données

L'exploitation des champs de texte libre peut apporter de la valeur : SSC recommande de procéder à des examens périodiques des résultats de l'exploration de texte dans les champs de texte libre afin de vérifier l'exactitude et le contrôle des données. Les opérations ont demandé au CSAA d'effectuer une analyse d'exploration de texte de ces champs. Le CSAA est en train de terminer cette analyse et continuera de le faire périodiquement.

Recommandations générales

Les informations supplémentaires découvertes tout au long du processus d'évaluation par les pairs devraient être intégrées à la documentation originale.