EXAMEN PAR LES PAIRS DU MODÈLE DE RECEVABILITÉ DES VISAS DE RÉSIDENCE TEMPORAIRE

Immigration, Réfugiés et Citoyenneté Canada
Immigration, Refugees and Citizenship Canada
Canada

Table des matières

Sommaire 3
1. Objectifs 3
2. Contexte 3
3. Besoins 4
4. Portée des travaux 4
5. Tâches 4
6. Activités 4
7. Analyse 5
7.1. Environnement 5
7.2. Cadre 5
7.3. Petite population (débalancement) 5
7.4. Modélisation 5
7.5. Réentraînement 6
7.6. Reproductibilité 6
8. Recommandations 6
9. Collaborations futures 8

Sommaire

Ce document fournit une évaluation par le Conseil national de recherches Canada (CNRC) en juillet 2018 de la méthodologie proposée pour évaluer la complexité des demandes de visa et les acheminer vers les agents appropriés pour leur traitement. Au moment de l'évaluation, cette méthodologie n'avait pas encore été mise en œuvre et les modèles examinés n'étaient pas utilisés. Cette évaluation ne couvre pas toutes les considérations liées à la Directive sur la prise de décisions automatisée du Secrétariat du Conseil du Trésor car celles-ci ont été introduites en 2019.

La méthodologie de l'initiative est excellente et suit les étapes nécessaires au succès d'un projet d'apprentissage machine. L'initiative est très bien adaptée aux différents risques organisationnels (légales, perception du public, sécurité) tout en maximisant les mesures de performance, c'est-à-dire la transparence de la méthodologie, l'efficacité des opérations et la qualité des données.

L'analyse fourni neuf recommandations et trois projets de collaboration avec le CNRC. Les sujets abordés incluent les modèles d'apprentissage automatique, l'environnement de travail, les algorithmes ainsi que de reproductibilité des résultats.

1. Objectifs

Immigration, Réfugiés et Citoyenneté Canada (IRCC) requiert les services du CNRC pour effectuer un examen scientifique/méthodologique des outils et des approches utilisés pour le déploiement de modèles prédictifs qui seront utilisés comme solution pour soutenir l'initiative de la Gestion du volume de la résidence temporaire (GVRT).

La justification de la réalisation d'un examen scientifique/méthodologique par une tierce partie indépendante est de garantir à la fois l'intégrité, la robustesse et la qualité du travail accompli jusqu'à présent.

En principe, une évaluation rapide inclut des phases-clés telles que la compréhension opérationnelle, la compréhension des données, la préparation des données, la modélisation, l'évaluation et le déploiement. Étant donné que le projet est relativement naissant, l'accent sera limité comme décrit dans la « Portée des travaux » ci-dessous.

Une fois l'examen rapide terminé, les deux participants détermineront si une évaluation plus détaillée serait nécessaire.

2. Contexte

Le Laboratoire d'analyse avancée (LAA) est chargé d'entreprendre le projet GVRT pour aider le Secteur des opérations à atteindre les résultats en matière de service à la clientèle et de gestion des risques d'intégrité dans plusieurs secteurs d'activité. La portée de cet examen inclut les demandeurs de visa de résident temporaire de la Chine reçus en ligne.

3. Besoins

L'examen scientifique/méthodologique est essentiellement un processus d'examen par les pairs consistant à appliquer des connaissances spécialisées sur des critères acceptables afin de déterminer si les outils et le protocole sont adéquats.

Un rapport de haut niveau décrira ce qui a été accompli jusqu'à présent, y compris une évaluation des mérites globaux et l'identification des outils et protocoles qui ont été mis en place.

L'examen scientifique/méthodologique est un processus constructif. L'objectif de l'examen est d'aider IRCC à répondre à un ensemble de critères minimum adéquats pour le travail qui a été accompli.

4. Portée des travaux

Le besoin est de retenir les services du CNRC pour fournir une expertise en services professionnels sur les objectifs suivants :

1. Examiner et évaluer les phases-clés des travaux entrepris jusqu'à présent dans les domaines suivants :
    a. Compréhension des données, en particulier sur la qualité des données ;
    b. Préparation des données : techniques de nettoyage des données et résultats, attributs dérivés et dossiers générés, approche d'intégration des données et agrégations ;
    c. Modélisation : technique et hypothèses de modélisation, conception de tests, construction de modèles (paramètres, modèles, descriptions), évaluation et révision des paramètres ;
    d. Évaluation (efficacité du modèle, lacunes).

5. Tâches

Les taches requises du CNRC incluent ce qui suit :

1. Élaborer un plan d'action pour mener l'examen
    a. Examiner la documentation
    b. Rencontrer les principales parties prenantes
2. Livrables et critères d'acceptation :
    a. Le plan
    b. Un rapport intérimaire
    c. Le rapport final sur l'examen détaillé et complet de la méthode

6. Activités

Deux réunions d'une journée chacune ont eu lieu à IRCC les 20 et 27 mars 2018, respectivement. Ceci constitue le rapport final.

7. Analyse

La méthodologie de l'initiative est excellente et suit les étapes nécessaires au succès d'un projet d'apprentissage machine. L'initiative est très bien adaptée aux différents risques organisationnels (légales, perception du public, sécurité) tout en maximisant les mesures de performance, c'est-à-dire la transparence de la méthodologie, l'efficacité des opérations et la qualité des données.

L'analyse a également vérifiée les modèles d'apprentissage automatique, l'environnement de travail, les algorithmes utilisés afin de fournir des recommandations. Une attention particulière a été mise sur la reproductibilité des résultats.

Avec l'exception d'une activité redondante de surajustement (*over-fitting*), l'environnement, l'approche et les algorithmes utilisés semblent être adéquats pour répondre au besoin du projet et sa mise en production. Dans les itérations futures, une attention plus équilibrée de la variabilité du modèle et le biais serait bénéfique. L'approche utilisée dans son ensemble pour garantir la reproductibilité des résultats est excellente, simple et claire.

7.1. Environnement

L'environnement SPSS est utilisé pour tout le traitement, la modélisation et le déploiement. Cet environnement est stable et bien supporté. Son désavantage est son manque de flexibilité; les options sont limitées à ce que SPSS offre.

7.2. Cadre

L'enjeu est de classifier des demandes de visas pour la Chine. Il y a trois ans de données étiquetées (approuvées ou non). L'entraînement des données se fait à l'écart (*batch*) et la performance est mesurée à l'aide de la précision de la prédiction des visas approuvés. L'approche utilisée suit les normes utilisées dans le domaine de l'apprentissage automatique.

7.3. Petite population (débalancement)

Le nombre de visas refusés est relativement petit par rapport à celui des visas approuvés. Les techniques de sous-échantillonnage utilisées pour réduire cet enjeu sont excellentes. Étant donné son impact réducteur sur la taille de l'échantillon, il serait utile de mieux comprendre l'effet de ce débalancement. Seulement une approche a été testée.

7.4. Modélisation

La modélisation utilise trois années de données. La partie entraînement est composée d'applications des trois années. La partie *cross-validation* (appelé testage) est composée de demandes de la dernière année seulement. Et la partie testage (appelé validation) est composée de mois ne faisant pas partie de l'échantillon d'entraînement ou de *cross-validation*.

La technique de modélisation utilisée pour ce projet est un arbre décisionnel (*decision tree*) qui est un excellent outil reconnu pour sa transparence mais relativement moins précis que d'autres. En revanche

quelques techniques de modélisation pourraient être améliorées et d'autres annulées. Une meilleure représentativité de la partie *cross-validation* à celle d'entraînement pourrait donner de meilleurs résultats. L'utilisation de chiffres aléatoires (*seed*) pour déterminer le meilleur modèle est inutile et met une pression inutile sur le surajustement (*over-fitting*). Il semble que les données plus vieilles ont moins de valeurs que les plus récentes. Ces deux enjeux montrent que les actions liées à la modélisation sont de nature à réduire le biais au profit de la variance du modèle.

7.5. Réentraînement

La décision de réentraîner les modèles tous les trois mois est excellente.

7.6. Reproductibilité

L'utilisation du logiciel SPSS, la documentation et la justification de chaque variable, l'utilisation de « seed », la transparence du modèle choisi sont excellents pour une reproductibilité des résultats et un transfert des connaissances. Le risque d'enjeux liés à la reproductibilité est réduit à son minimum.

8. Recommandations

Suite aux deux jours de consultations, neuf recommandations ont été identifiées.

1. Avoir une stratégie de surveillance sur le réapprentissage et mise à jour des paramètres au besoin.

   Réponse d'IRCC : Les indicateurs de performance-clés sont surveillés chaque semaine par plusieurs parties prenantes. Un réapprentissage est effectué si une détérioration de ces indicateurs suggère la nécessité de mettre à jour le modèle.

2. Modifier l'unité d'analyse à « famille » au lieu de « personne ».

   Réponse d'IRCC : IRCC a maintenu une analyse basée sur des clients individuels parce que cette approche est plus exhaustive. Lorsque plusieurs clients voyagent ensemble en groupe, l'analyse prend en considération les informations sur chaque membre du groupe pour guider le triage.

3. Uniformiser l'apprentissage au groupe « validation » (aussi appelé *Testing* dans la littérature) pour que les données d'entraînement soit semblables aux données tests.

   Réponse d'IRCC : IRCC a modifié son approche à la suite de l'examen par le CNRC afin de soutenir une plus grande représentativité des données de validation. Cet échantillon englobe désormais des demandes provenant de différentes parties de l'année afin de garantir que les tendances saisonnières dans la réception des demandes soient capturées. Les données de validation sont également sélectionnées parmi les demandes traitées les plus récentes afin de garantir que le modèle se généralise avec précision aux tendances les plus récentes du programme.

4. Dans un environnement parallèle, développer des modèles plus sophistiqués en commençant par : Random Forest, SVM, Neural network, Deep learning, etc.

Réponse d'IRCC : Certaines expériences ont été entreprises avec d'autres types de modèles dans notre environnement de test (jamais mises en œuvre). Les gains en précision étaient marginaux et se faisaient au détriment d'une perte significative dans la capacité à expliquer les prédictions du modèle. Cela n'aurait pas été acceptable à la lumière des efforts d'IRCC pour utiliser la technologie de manière responsable. Par conséquent, les arbres de décision ont été conservés comme le type de modèle pour ce projet.

5. Augmenter, voir doubler ou tripler, la taille du groupe d'entraînement (approuvé) même si le nombre de refus est relativement petit.

   Réponse d'IRCC : Certaines expériences ont été entreprises avec une plus grande représentation des demandes approuvées dans l'échantillon de formation. Cependant, les meilleurs modèles ont été obtenus lorsque les données de formation étaient à peu près équilibrées entre les demandes approuvées et refusées.

6. Augmenter l'échantillon en combinant les données de d'autres pays d'origine.

   Réponse d'IRCC : Cette approche a été appliquée à l'Inde en 2018 et à tous les autres pays en 2022.

7. Utilisation du « clustering » pour mieux comprendre les différences entre les saisons, les pays, etc. et l'analyse de la fraude.

   Réponse d'IRCC : La plupart des données utilisées pour entraîner le modèle sont non numériques, ce qui les rend moins propices aux techniques d'analyse par segmentation. IRCC a expérimenté avec des distances de Gower adaptées aux données non numériques, mais les résultats n'ont pas été utiles. D'autres outils ont été développés pour l'analyse de la fraude.

8. Considérer l'utilisation de logiciels libres tels R ou Python pour expérimenter de nouvelles approches et avoir plus de flexibilité sur la modélisation.

   Réponse d'IRCC : IRCC migre tous ses modèles vers Python pour réduire les coûts, augmenter les fonctionnalités et améliorer la productivité de l'équipe d'analytique.

9. Expérimenter les différentes formes de débalancement. Identifier l'approche qui optimise la précision des résultats.

   Réponse d'IRCC : IRCC a expérimenté avec différentes approches pour remédier au déséquilibre dans les données de formation. Les meilleurs modèles ont été obtenus lorsque les données de formation étaient à peu près équilibrées entre les demandes approuvées et refusées.

9. Collaborations futures

Différentes opportunités de collaboration entre le IRCC et le CNRC ont également été abordées:

1. *(Caviardé suivant la section 16 de la Loi sur l'accès à l'information).*
2. Utiliser les plateformes de calcul du CNRC pour tester des modèles plus complexes.
3. Développer du code pour des modèles plus sophistiqués (en R ou Python par exemple).